

Classification Analysis pada Dataset Dry Bean Menggunakan Metode Analisis Diskriminan dan Multinomial Logistic Regression

Andika Febrianto¹, Dian Rohmatul Islam², Afifah³

^{1,2,3}Sains Data, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri

Surabaya

124031554018@mhs.unesa.ac.id

224031554047@mhs.unesa.ac.id

324031554202@mhs.unesa.ac.id

Analisis Multivariat 2024A

Dosen Pengampu: Dinda Galuh Guminta, S.Stat., M.Stat.

Abstract: This classification analysis aims to classify types of dried beans based on the Dry Bean Dataset from the UCI Machine Learning Repository using the Multinomial Logistic Regression and Discriminant Analysis method. The dataset consists of 13,611 observations across seven categories of dried beans. The data was processed through preprocessing steps, including checking for missing values, removing duplicate data, standardizing numerical variables, and identifying outliers. The variables used were selected through variable selection, namely AspectRatio, ShapeFactor1, ShapeFactor4, Extent, and Solidity, to reduce multicollinearity and obtain a more stable model. Model evaluation was conducted through assumption testing and classification performance measurement. The analysis results show that the final model is capable of delivering excellent performance with an accuracy of 92.24%, a Kappa value of 0.9061, and a McFadden Pseudo R^2 of 0.885. This analysis indicates that multinomial logistic regression is effective for multiclass classification based on the geometric characteristics of dry seeds.

Keywords: Dry Bean Dataset, Multinomial Logistic Regression, Multiclass Classification, Data Preprocessing, Geometric Characteristics of Beans

Abstrak: Analisis klasifikasi ini bertujuan untuk mengklasifikasikan jenis biji kering berdasarkan Dry Bean Dataset dari UCI Machine Learning Repository menggunakan metode Multinomial Logistic Regression Discriminant Analysis. Dataset terdiri dari 13.611 observasi dengan tujuh kategori jenis biji kering. Data diproses melalui tahap preprocessing meliputi pengecekan missing value, penghapusan data duplikat, standarisasi variabel numerik, dan identifikasi outlier. Variabel yang digunakan merupakan hasil seleksi variabel, yaitu AspectRatio, ShapeFactor1, ShapeFactor4, Extent, dan Solidity untuk mengurangi multikolinearitas dan memperoleh model yang lebih stabil. Evaluasi model dilakukan melalui pengujian asumsi serta pengukuran performa klasifikasi. Hasil analisis menunjukkan bahwa model akhir mampu memberikan performa yang sangat optimal dengan akurasi sebesar 92,24%, nilai Kappa sebesar 0,9061, dan Pseudo R^2 McFadden sebesar 0,885. Analisis ini menunjukkan bahwa regresi logistik multinomial efektif digunakan untuk klasifikasi multikelas berdasarkan karakteristik geometris biji kering.

Kata Kunci: Dry Bean Dataset, Multinomial Logistic Regression, Klasifikasi Multikelas, Preprocessing Data, Karakteristik Geometris Biji

I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi dan penerapan metode *machine learning* dalam bidang pertanian telah menghasilkan berbagai dataset dengan jumlah observasi dan variabel yang besar, termasuk data karakteristik geometris biji kering. Salah satu dataset yang banyak digunakan dalam analisis klasifikasi multikelas adalah Dry Bean Dataset yang memuat informasi morfologi berbagai jenis biji berdasarkan hasil ekstraksi citra digital [1]. Data tersebut sering dianalisis untuk mengidentifikasi dan mengklasifikasikan jenis biji secara berdasarkan karakteristik fisiknya.

Namun, data multivariat dengan banyak variabel numerik memiliki kompleksitas yang tinggi serta memiliki hubungan antarvariabel yang kuat. Kondisi tersebut dapat menimbulkan masalah multikolinearitas dan mempengaruhi stabilitas model klasifikasi. Oleh karena itu, diperlukan metode analisis yang dapat melakukan klasifikasi multikelas secara efektif serta menghasilkan model yang stabil dan akurat [3].

Analisis klasifikasi merupakan salah satu metode dalam Multivariate Analysis yang digunakan untuk mengelompokkan objek ke dalam kategori tertentu berdasarkan karakteristik variabel prediktor. Salah satu metode yang sering digunakan dalam klasifikasi multikelas adalah *Multinomial Logistic Regression*. Metode ini dapat memodelkan hubungan antara variabel dependen kategorik dengan beberapa variabel independen numerik maupun kategorik [5]. Selain itu, regresi logistik multinomial efektif dalam menangani permasalahan klasifikasi dengan lebih dari dua kategori kelas [7].

Selain regresi logistik multinomial, metode *Discriminant Analysis* juga banyak digunakan dalam proses klasifikasi data multikelas. Beberapa analisis menunjukkan bahwa kedua metode tersebut memiliki karakteristik dan performa yang berbeda tergantung pada struktur data yang digunakan [4]. Analisis sebelumnya juga menunjukkan bahwa klasifikasi pada data dry bean dapat

memberikan hasil yang optimal menggunakan model statistik maupun *machine learning* [1], [9]. Oleh karena itu, diperlukan analisis klasifikasi pada Dry Bean Dataset menggunakan metode analisis diskriminan dan regresi logistik multinomial untuk mengetahui kemampuan model dalam mengklasifikasikan jenis biji kering berdasarkan karakteristik geometrisnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam analisis ini adalah:

1. Bagaimana proses preprocessing data pada Dry Bean Dataset untuk menghasilkan data clean yang digunakan dalam analisis klasifikasi?
2. Bagaimana penerapan metode *Discriminant Analysis* dan *Multinomial Logistic Regression* dalam mengklasifikasikan jenis biji kering berdasarkan karakteristik geometrisnya?
3. Bagaimana performa model klasifikasi yang dihasilkan berdasarkan nilai evaluasi klasifikasi seperti akurasi, Kappa, dan Pseudo R^2 ?
4. Metode manakah yang memberikan performa klasifikasi terbaik pada Dry Bean Dataset?

1.3 Tujuan

Berdasarkan rumusan masalah tersebut, tujuan analisis ini adalah sebagai berikut:

1. Melakukan preprocessing data pada Dry Bean Dataset agar data siap digunakan dalam proses analisis klasifikasi
2. Menerapkan metode *Discriminant Analysis* dan *Multinomial Logistic Regression* untuk mengklasifikasikan jenis biji kering berdasarkan karakteristik geometrisnya
3. Mengevaluasi performa model klasifikasi menggunakan ukuran evaluasi seperti akurasi, Kappa, dan Pseudo R^2
4. Membandingkan performa kedua metode untuk menentukan metode klasifikasi terbaik pada Dry Bean Dataset

II. METODE ANALISIS

2.1 Deskripsi Dataset

Data pada analisis ini memberikan gambaran mengenai karakteristik geometris berbagai jenis biji kering berdasarkan hasil ekstraksi citra digital. Dataset yang digunakan adalah Dry Bean Dataset yang diperoleh dari UCI Machine Learning Repository. Dataset terdiri dari 13.611 observasi, di

mana setiap observasi merepresentasikan satu sampel biji kering dengan karakteristik bentuk dan ukuran yang berbeda. Variabel dependen yang digunakan dalam analisis ini adalah *Class*, yang terdiri dari tujuh kategori jenis biji kering, yaitu Barbunya, Bombay, Cali, Dermason, Horoz, Seker, dan Sira. Sedangkan, variabel independen berupa variabel numerik yang merepresentasikan karakteristik geometris biji, seperti ukuran, bentuk, rasio, dan tingkat kepadatan objek hasil citra digital. Pada analisis ini, variabel yang digunakan merupakan hasil seleksi variabel, yaitu *AspectRatio*, *ShapeFactor1*, *ShapeFactor4*, *Extent*, dan *Solidity*, untuk mengurangi multikolinearitas dan memperoleh model klasifikasi yang lebih stabil.

Seluruh variabel yang digunakan, dilakukan tahap preprocessing berupa pengecekan missing value, penghapusan data duplikat, standarisasi variabel numerik, serta identifikasi outlier sebelum dilakukan proses analisis klasifikasi. Variabel tersebut kemudian digunakan untuk menerapkan metode *Discriminant Analysis* dan *Multinomial Logistic Regression* dalam mengklasifikasikan jenis biji kering berdasarkan karakteristik geometrisnya, seperti yang ditunjukkan pada Tabel 1 yang berisi daftar variabel yang digunakan dalam analisis.

Tabel 1. Variable Analysis

Simbol	Nama Variable	Keterangan
Y	Class	Jenis biji kering
X1	AspectRatio	Rasio panjang dan lebar biji
X2	ShapeFactor1	Faktor bentuk 1
X3	ShapeFactor4	Faktor bentuk 4
X4	Extent	Ukuran penyebaran bentuk biji
X5	Solidity	Tingkat kepadatan bentuk biji

2.2 Multinomial Logistic Regression

Multinomial Logistic Regression merupakan metode klasifikasi yang digunakan untuk memodelkan hubungan antara variabel dependen kategorik dengan lebih dari dua kategori dan beberapa variabel independen [3], [5]. Metode ini bekerja dengan mengestimasi probabilitas suatu object masuk ke dalam kategori tertentu berdasarkan karakteristik variabel prediktor yang digunakan. Proses pembentukan model dilakukan menggunakan metode maximum likelihood estimation untuk memperoleh parameter model yang optimal [3]. Hubungan antara variabel dependen dan variabel independen dinyatakan dalam bentuk fungsi logit

multinomial, yaitu perbandingan peluang suatu kategori terhadap kategori referensi.

$$\ln\left(\frac{P(Y=j)}{P(Y=\text{dasar})}\right) = \beta_{0j} + \beta_{1j}X_1 + \beta_{2j}X_2 + \beta_{3j}X_3 + \beta_{4j}X_4$$

Gambar 1. Rumus Multinomial Logistic Regression. Sumber: https://www.rpubs.com/Olivia_Pesireron/Regresi_Logistik_Multinomial

Rumus regresi logistik multinomial pada gambar 1 digunakan untuk memodelkan hubungan antara variabel dependen kategorik multikelas dengan beberapa variabel independen [3], [5]. Model ini membandingkan peluang suatu observasi masuk ke kategori tertentu terhadap kategori dasar (*reference category*) menggunakan fungsi logit. Nilai koefisien regresi menunjukkan besar dan arah pengaruh masing-masing variabel independen terhadap probabilitas suatu kategori [7].

2.3 Discriminant Analysis

Discriminant Analysis merupakan metode klasifikasi dalam *Multivariate Analysis* yang digunakan untuk mengelompokkan objek ke dalam kategori tertentu berdasarkan kombinasi variabel independen [2], [4]. Metode ini bekerja dengan membentuk fungsi diskriminan yang mampu memaksimalkan perbedaan antar kelompok sehingga setiap observasi dapat diklasifikasikan ke kelas yang paling sesuai. Analisis diskriminan digunakan ketika variabel dependen berbentuk kategorik dan variabel independen berupa data numerik. Metode ini memiliki beberapa asumsi, seperti normalitas multivariat, homogenitas matriks kovarians, dan independensi observasi [4]. Fungsi diskriminan dibentuk dari kombinasi linear variabel prediktor seperti pada gambar 2.

$$d_i^L(\mathbf{x}) = -\frac{1}{2}\mu_i'\Sigma^{-1}\mu_i + \mu_i'\Sigma^{-1}\mathbf{x} = d_{i0} + \sum_{j=1}^p d_{ij}x_j$$

$$d_{i0} = -\frac{1}{2}\mu_i'\Sigma^{-1}\mu_i$$

Gambar 2. Rumus Fungsi Diskriminan Linear. Sumber: <https://online.stat.psu.edu/stat505/lesson/10/10.3>

Pada gambar 2, fungsi tersebut dibentuk menggunakan rata-rata setiap kelompok, matriks kovarians, dan variabel independen untuk menghasilkan skor diskriminan pada masing-masing kelas. Observasi kemudian diklasifikasikan ke kelompok yang memiliki nilai skor diskriminan terbesar [4], [8].

2.4 Uji Asumsi dan Seleksi Variabel

Uji asumsi dilakukan untuk memastikan bahwa model *Multinomial Logistic Regression* dan *Discriminant Analysis* memenuhi syarat analisis sehingga menghasilkan model yang stabil dan akurat. Pengujian yang dilakukan meliputi *independence of observation*, uji multikolinearitas menggunakan *Variance Inflation Factor* (VIF), serta uji linearitas logit pada regresi logistik multinomial [3], [5]. Selain itu, dilakukan seleksi variabel untuk memilih variabel prediktor yang paling relevan dan mengurangi hubungan yang terlalu kuat antar variabel. Seleksi variabel bertujuan untuk memperoleh model yang lebih sederhana namun tetap memiliki performa klasifikasi yang baik [4], [7]. Variabel yang digunakan dalam model akhir yaitu *AspectRatio*, *ShapeFactor1*, *ShapeFactor4*, *Extent*, dan *Solidity*.

2.5 Uji Signifikansi dan Interpretasi Model

Uji signifikansi dilakukan untuk mengetahui pengaruh variabel independen terhadap model *Multinomial Logistic Regression*. Pengujian dilakukan menggunakan *Likelihood Ratio Test* untuk menguji pengaruh variabel dan *Wald Test* untuk menguji pengaruh masing-masing variabel secara parsial [5], [7]. Variabel dikatakan signifikan apabila memiliki nilai *p-value* lebih kecil dari tingkat signifikansi yang digunakan. Interpretasi model dilakukan menggunakan nilai *Relative Log Odds* dan *Relative Risk Ratio* (RRR) untuk melihat arah serta besar pengaruh variabel prediktor terhadap peluang suatu observasi masuk ke kategori tertentu [3]. Selain itu, digunakan marginal effects untuk mengetahui perubahan probabilitas kategori akibat perubahan nilai variabel independen [4], [7].

2.6 Evaluasi Model

Evaluasi model dilakukan untuk mengukur performa klasifikasi dari metode *Multinomial Logistic Regression* dan *Discriminant Analysis*. Pengukuran performa dilakukan menggunakan confusion matrix, accuracy, nilai Kappa, serta Pseudo R^2 McFadden [5], [7]. Nilai accuracy digunakan untuk menunjukkan persentase klasifikasi yang benar, sedangkan Kappa digunakan untuk mengukur tingkat kesesuaian model terhadap data aktual. Selain itu, Pseudo R^2 McFadden digunakan untuk mengevaluasi kecocokan model regresi logistik multinomial. Semakin tinggi nilai evaluasi

yang diperoleh, maka semakin baik kemampuan model dalam mengklasifikasikan jenis biji kering berdasarkan karakteristik geometrisnya [3], [4].

III. HASIL DAN PEMBAHASAN

3.1 Karakteristik Dataset

Tabel 2. Statistika Deskriptif

Variable	Min	Q1	Med	Mean	Q3	Max
Aspecratio	-2.26	-0.61	-0.12	0.00	0.50	3.46
ShapeFactor1	-3.34	-0.59	0.07	0.00	0.62	3.44
ShapeFactor4	-10.90	-0.31	0.30	0.00	0.64	1.07
Extent	-3.97	-0.63	0.20	0.00	0.75	2.37
Solidity	-14.60	-0.31	0.24	0.00	0.61	1.61

Tabel 3. Distribusi Kelas

Class	Jumlah
BARBUNYA	1322
BOMBAY	522
CALI	1630
DERMASON	3546
HOROZ	1860
SEKER	2027
SIRA	2636

Berdasarkan hasil statistika deskriptif pada Tabel 2, seluruh variabel memiliki nilai rata-rata (*mean*) sebesar 0 yang menunjukkan bahwa proses standarisasi menggunakan metode *z-score* telah berhasil dilakukan dengan optimal. Nilai median pada sebagian besar variabel berada di sekitar nol sehingga distribusi data relatif terpusat setelah proses standarisasi. Variabel *AspectRatio*, *ShapeFactor1*, *ShapeFactor4*, *Extent*, dan *Solidity* memiliki rentang nilai yang cukup beragam, yang menunjukkan adanya variasi karakteristik geometris antar jenis biji kering. Selain itu, beberapa variabel memiliki nilai minimum yang cukup ekstrem, seperti *ShapeFactor4* dan *Solidity*, yang mengindikasikan adanya observasi dengan karakteristik yang sangat berbeda dibandingkan sebagian besar data lainnya.

Berdasarkan Tabel 3, distribusi jumlah observasi pada setiap kelas menunjukkan bahwa kelas DERMASON memiliki jumlah data terbanyak yaitu 3.546 observasi, sedangkan kelas BOMBAY memiliki jumlah observasi paling sedikit yaitu 522 data. Perbedaan proporsi antar kelas menunjukkan bahwa distribusi data pada dataset cenderung tidak seimbang. Namun, seluruh kelas masih memiliki jumlah observasi yang cukup untuk digunakan dalam proses klasifikasi menggunakan metode *Discriminant Analysis* dan *Multinomial Logistic Regression*.

Tabel 7, sebagian besar observasi berhasil diprediksi sesuai dengan kelas aktualnya, meskipun masih terdapat beberapa kesalahan klasifikasi pada beberapa kategori seperti CALI, SEKER, dan SIRA.

Nilai *score prediksi* pada Tabel 8 sebesar 0,9015 menunjukkan bahwa model analisis diskriminan memiliki tingkat akurasi sebesar 90,15%. Nilai tersebut menunjukkan bahwa model memiliki kemampuan klasifikasi yang cukup tinggi dalam membedakan tujuh kategori dry bean.

3.5 Analisis Perbandingan Metode

Berdasarkan hasil evaluasi model, metode *Multinomial Logistic Regression* dan *Discriminant Analysis* mampu melakukan klasifikasi jenis biji kering dengan performa yang optimal. Namun, regresi logistik multinomial menunjukkan performa yang lebih tinggi dibandingkan analisis diskriminan. Model regresi logistik multinomial memperoleh nilai akurasi sebesar 92,24%, sedangkan analisis diskriminan memperoleh akurasi sebesar 90,15%. Perbedaan hasil tersebut menunjukkan bahwa regresi logistik multinomial memiliki kemampuan yang lebih optimal dalam menangkap hubungan antar variabel dan memodelkan klasifikasi multikelas pada dataset dry bean. Selain itu, regresi logistik multinomial juga lebih fleksibel karena tidak terlalu bergantung pada asumsi normalitas multivariat seperti pada analisis diskriminan [4], [8].

Disisi lain, analisis diskriminan tetap menunjukkan performa klasifikasi yang tinggi dengan tingkat akurasi di atas 90%. Hal ini menunjukkan bahwa variabel geometris seperti *AspectRatio*, *ShapeFactor1*, *ShapeFactor4*, *Extent*, dan *Solidity* memiliki kemampuan diskriminatif yang baik dalam membedakan jenis biji kering. Maka, dapat dikatakan kedua metode efektif digunakan untuk klasifikasi multikelas, namun regresi logistik multinomial memberikan hasil yang lebih optimal pada analisis ini.

IV. KESIMPULAN

Berdasarkan hasil analisis, metode *Multinomial Logistic Regression* dan *Discriminant Analysis* berhasil diterapkan untuk mengklasifikasikan tujuh jenis biji kering pada Dry Bean Dataset berdasarkan karakteristik geometris biji. Pada tahap preprocessing, data berhasil melalui proses pengecekan missing value, penghapusan data

duplikat, standarisasi variabel, serta seleksi variabel sehingga dataset berada dalam kondisi yang baik untuk proses pemodelan klasifikasi. Hasil analisis menunjukkan bahwa regresi logistik multinomial mampu memberikan performa klasifikasi yang sangat optimal dengan nilai akurasi sebesar 92,24%, sedangkan analisis diskriminan memperoleh akurasi sebesar 90,15%. Kedua metode mampu mengklasifikasikan sebagian besar observasi dengan benar, yang menunjukkan bahwa variabel *AspectRatio*, *ShapeFactor1*, *ShapeFactor4*, *Extent*, dan *Solidity* memiliki kemampuan yang baik dalam membedakan masing-masing jenis dry bean. Selain itu, hasil analisis menunjukkan bahwa regresi logistik multinomial lebih unggul dibandingkan analisis diskriminan dalam menangkap pola hubungan antar variabel pada data multikelas. Namun, analisis diskriminan tetap menunjukkan performa yang baik dengan tingkat akurasi yang tinggi. Oleh karena itu, dapat disimpulkan bahwa kedua metode efektif digunakan dalam analisis klasifikasi multikelas.

DAFTAR PUSTAKA

- [1] M. Koklu and I. A. Ozkan, "Multiclass classification of dry beans using computer vision and machine learning techniques," *Computers and Electronics in Agriculture*, vol. 174, p. 105507, Jul. 2020, doi: 10.1016/j.compag.2020.105507.
- [2] A. S. R. P. Wardhani, "Perbandingan analisis diskriminan dan regresi logistik multinomial pada klasifikasi penderita hipertensi," *Jurnal Ilmiah KOMPUTASI dan Informatika (IKOMTI)*, vol. 2, no. 1, 2024.
- [3] G. K. G. M. Dissanayake, "Multinomial logistic regression for data analysis," *SAGE Research Methods Cases*, 2016, doi: 10.1177/2059799116672874.
- [4] A. S. Fouladi, N. R. N. Khameneh, and M. R. Mahmoudi, "Multinomial logistic regression and discriminant function analysis in medical research: a comparison study," *Journal of Applied Statistics*, vol. 45, no. 3, pp. 461–474, 2018, doi: 10.1080/02664763.2017.1282441.
- [5] S. Menard, "Applied logistic regression analysis," *SAGE Research Methods Foundations*, 2016, doi: 10.1177/1471082X16642560.
- [6] C. Molnar, "Interpretable machine learning," *arXiv preprint arXiv:1604.04706*, 2016.

- [7] M. F. M. Arif, M. R. Hossain, and S. Akter, "A review of multinomial logistic regression in classification problems," *Results in Engineering*, vol. 20, p. 101565, 2023.
- [8] Y. Zhang, L. Chen, and X. Wang, "Comparative analysis of discriminant analysis and multinomial logistic regression for multiclass classification," *Scientific Reports*, vol. 15, Art. no. 604, 2025.
- [9] H. Demir, E. Ceyhan, and M. Koklu, "Classification of dry bean genotypes using morphological traits and machine learning approaches," *Euphytica*, vol. 222, Art. no. 87, 2026.

LAMPIRAN

A. Sample Dataset: <https://archive.ics.uci.edu/dataset/602/dry+bean+dataset>

Area	Perimeter	MajorAxisLength	...	ShapeFactor3	ShapeFactor4	Class
28395	610,291	208,178116708527		0,834222388245556	0,998723889013168	SEKER
28734	638,018	200,524795663648		0,909850506397935	0,998430331449707	SEKER
			⋮			
42147	763,779	190,275730770994		0,668236683842453	0,995222419726149	DERMASON
42159	772,237	182,204715895513		0,61622059234089	0,998179623305468	DERMASON

B. Link R-Pubs

<https://rpubs.com/andkfbrnt018/1431046>

C. Link Github

<https://github.com/AndikaFebrianto018/CLASIFICATION-ANALYSIS-DRY-BEAN-DATASET->